EXOPLANET TRANSIT TIMING VARIATION CLASSIFICATION

Il dataset scelto contiene 36 variabili riguardanti determinate caratteristiche di 5514 esopianeti. Come variabile target binaria si considera *ttv_flag*, che assume valore 1 quando un pianeta mostra variazione nel tempo dei tempi di transito. Questo potrebbe essere dovuto dalla presenza di un altro pianeta nel sistema, non osservabile con metodi tradizionali. Se non si osserva nessuna variazione nell'orbita, la variabile risposta assume valore 0. Lo scopo delle analisi è valutare la presenza o meno di variazione del tempo di transito in relazione ad altre importanti caratteristiche degli esopianeti. Seguono tutte le covariate, comprese quelle che non verranno mantenute in analisi.

1. *pl_name*: nome del pianeta;
2. *hostname*: nome della stella del sistema in cui orbita il pianeta;
3. *sy_snum*: numero di stelle nel sistema;
4. *sy_pnum*: numero di pianeti nel sistema;
5. *disc_facility:* nome dell'osservatorio da cui è stato scoperto il pianeta;
6. *disc_telescope*: nome del telescopio utilizzato nell'osservatorio;
7. *pl_orbper*: periodo orbitale del pianeta;
8. *pl_orbmax*: semiasse maggiore dell'orbita ellittica del pianeta;
9. *pl_rade*: raggio del pianeta rapportato al raggio terrestre;
10. *pl_radj*: raggio del pianeta rapportato al raggio di Giove;
11. *pl_bmasse*: miglior stima della massa del pianeta in rapporto alla massa terreste;
12. *pl_bmassj*: miglior stima della massa del pianeta in rapporto alla massa di Giove;
13. *pl_bmassprov*: formula utilizzata per calcolare la massa del pianeta;
14. *pl_dens*: densità del pianeta misurata in g/cm^3;
15. *pl_orbeccen*: eccentricità dell'orbita planetaria;
16. *pl_insol*: irraggiamento solare;
17. *pl_eqt*: temperatura di equilibrio misurata in kelvin;
18. *pl_orbincl*: inclinazione dell'orbita planetaria;
19. *pl_impar*: distanza tra il centro della stella e il centro del pianeta, normalizzato rispetto al raggio della stella;
20. *pl_orblper*: separazione angolare tra nodo ascendente dell'orbita e il punto più vicino in un'orbita ellittica intorno ad una stella (periastron);
21. *st_spectype*: classificazione della stella basata sulle caratteristiche spettrali che segue il sistema di Morgan-Keenan.;
22. *st_teff*: temperatura effettiva della stella misurata in kelvin;
23. *st_mass*: massa stellare;
24. *st_lum*: luminosità della stella;
25. *st_logg*: gravità della superficie stellare;
26. *rastr*: raggio ascensionale del sistema planetario in formato sessagesimale;
27. *ra*: raggio ascensionale del sistema planetario in formato decimale;
28. *decstr*: declinazione del pianeta in notazione sessagesimale;
29. *dec*: declinazione del pianeta in notazione decimale;
30. *sy_dist*: distanza della Terra dal sistema planetario misurata in parsec;

31. *sy_vmag*: luminosità della stella ospitante misurata usando la banda V di Johnson;
32. *sy_kmag*: luminosità della stella ospitante misurata usando la banda K;
33. *sy_gaiamag*: luminosità della stella ospitante misurata la banda di Gaia;
34. *sygaiamagerr1*: estremo superiore dell'intervallo di confidenza della magnitudine di Gaia;
35. *sygaiamagerr2*: estremo inferiore dell'intervallo di confidenza della magnitudine di Gaia;

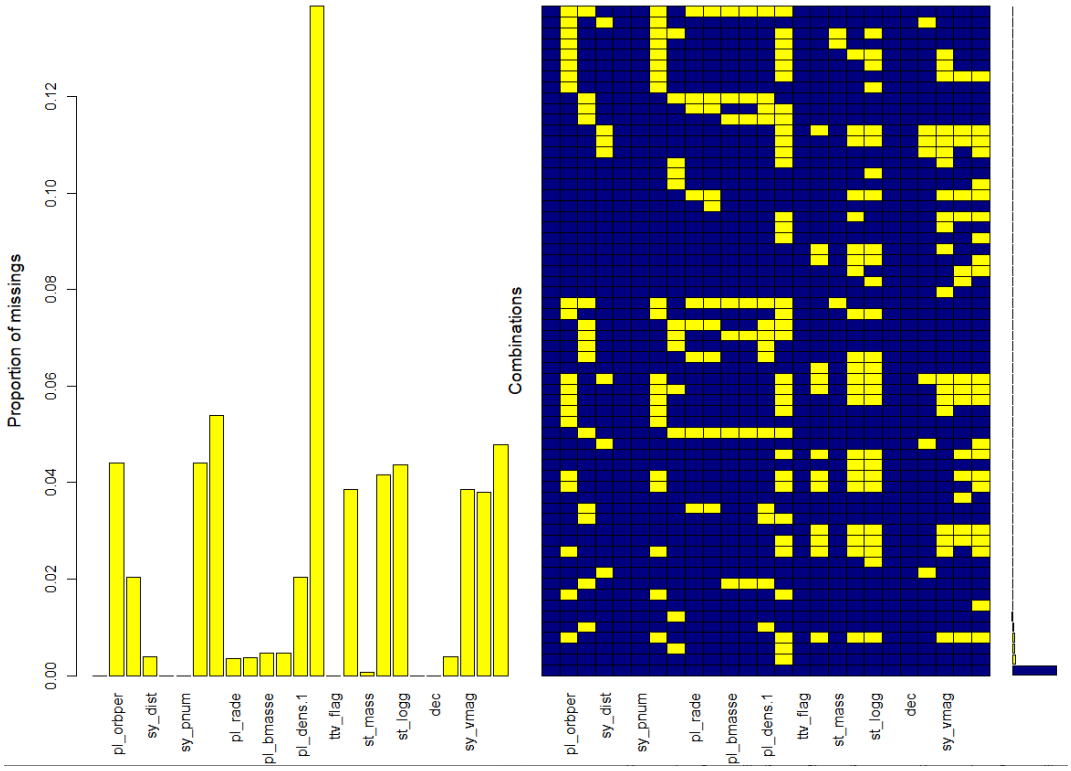
ANALISI PRELIMINARE DELLE VARIABILI

Sono state eliminate dal dataset di partenza le variabili *pl_name* e *hostname* in quanto variabili identificative. Sono inoltre state escluse anche le variabili *rastr* e *decstr* perché sono il formato sessagesimale dei caratteri *ra* e *dec.* Infine si è scelto di non considerare nello studio le variabili *sygaiamagerr1* e *sygaiamagerr2,* perché rappresentano gli estremi dell'intervallo di confidenza di *sy_gaiamag.*

Zero variance e factor

Nella fase di pre-processing sono state individuate le variabili qualitative per trasformarle in binomiali e categoriali. In seguito sono stati valutati i livelli delle categoriche e calcolate le varianze delle quantitative. Dato che nessuna variabile ha presentato un solo livello o varianza nulla, nessun carattere è stato escluso.

Visualizzazione dei dati mancanti



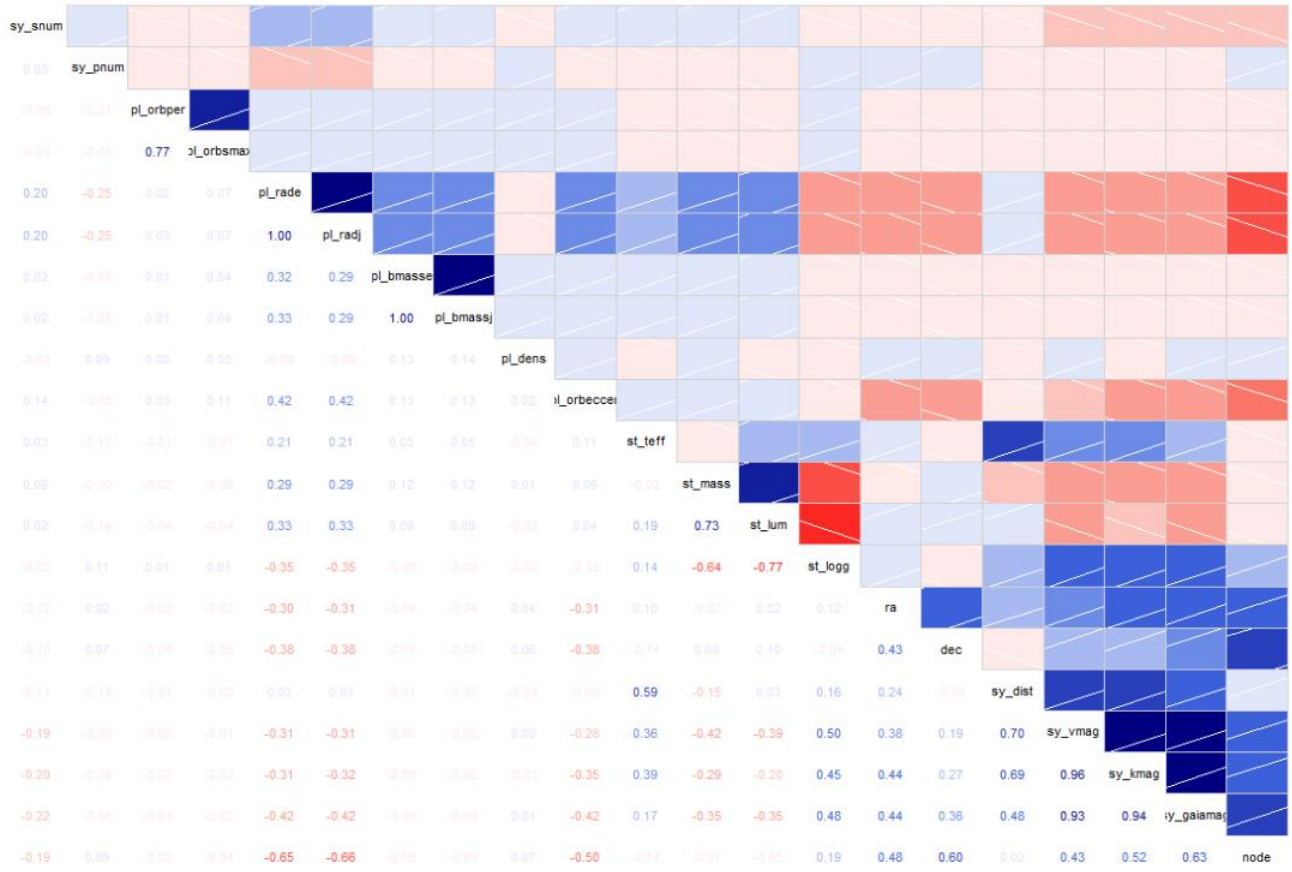
La fase antecedente alla costruzione del modello riguarda lo studio dei valori mancanti all'interno del dataset. Sono stati conteggiati i valori mancanti per ogni variabile. Dallo studio è emerso che le covariate *pl_insol*, *pl_eqt*, *pl_orbincl*, *pl_imppar*, *pl_orblper* e *st_spectype* presentano una proporzione elevata di dati mancanti (> 20%). Di conseguenza si è scelto di escludere le covariate citate. Nella figura in alto è possibile visualizzare graficamente la distribuzione dei dati mancanti all'interno del dataset dopo aver escluso le variabili più problematiche.
È stato notato che la variabile *disc_telescope* presentava troppi livelli da gestire. Di conseguenza è stato effettuato l'optimal grouping in relazione alla variabile target ed è stato ricavato un carattere analogo (*node*) con solo quattro livelli.

Imputazione dati mancanti con random forest
Essendo presenti nel dataset dati mancanti è necessario effettuare una stima di essi per procedere. Per stimare i dati mancanti si utilizza la procedura di imputazione con random forest, che è più robusta rispetto alla mice imputation.

Collinearità
Le variabili sono state divise in numeriche e categoriali. Per quelle numeriche è stata fatta un'analisi della collinearità.
L'immagine seguente mostra che la correlazione tra le variabili:

1. *pl_rade* e *pl_radj* è pari ad 1;
2. *pl_bmasse* e *pl_bmassj* è pari ad 1;
3. *sy_vmag* e *sy_kmag* è pari a 0.96;
4. *sy_kmag* e *sy_gaiamag* è pari a 0.94;
5. *sy_vmag* e *sy_gaiamag*è è pari 0.93.

Si è scelto di eliminare i caratteri *pl_radj*, *pl_bmassj*, *sy_kmag*, *sy_gaiamag.*



Bilanciamento del dataset

Nel nostro caso la proporzione di osservazioni a cui era associato il valore 0 alla variabile target era troppo elevata (93%) rispetto alla popolazione di riferimento (87%). Di conseguenza per bilanciare il dataset si è scelto il metodo dell'undersampling. In particolare sono state escluse alcune osservazioni in cui era assente la variazione nel tempo dei tempi di transito, in modo casuale e stratificato per il carattere dipendente.

Training, validation e score

Si procede con la divisione del dataset in training, validation e score, utilizzando la tecnica di model validation nota come metodo holdout. I modelli competitivi proposti verranno allenati nel dataset di training e poi validati sul dataset di validation per verificare che non avvenga un'eccessiva specializzazione (overfitting) dei modelli sui dati di training, che non permetta di utilizzare i modelli stessi su altri dati. Si è deciso di suddividere il dataset considerando una proporzione dei dati pari al 60% nella fase di allenamento, 30% nella fase di validazione e infine il 10% nella fase di score.

STEP 1: MODELLI COMPETITIVI

Conclusa la fase di preprocessing si procede alla preparazione dei modelli, sia che seguono l'approccio del classificatore bayesiano, sia modelli che non forniscono direttamente probabilità previste, ma punteggi discriminanti. Al fine di raggiungere l'obiettivo dell'analisi si è deciso di utilizzare una metrica robusta quale la ROC per tunare i modelli proposti.

1. Classification Tree

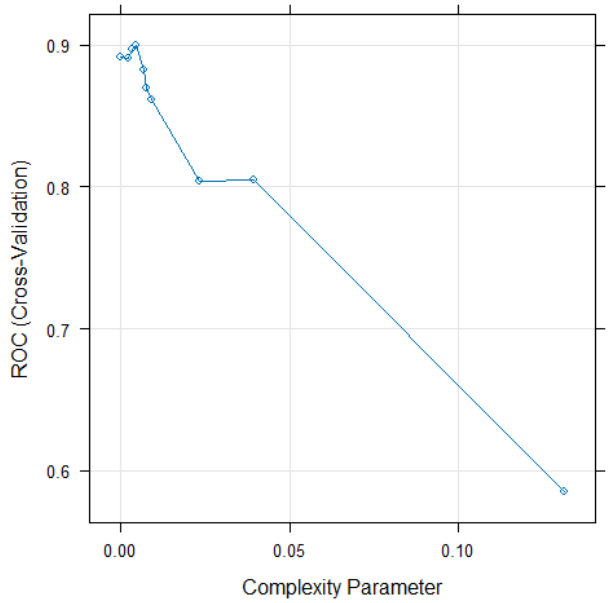
Il primo modello proposto è un albero decisionale che procede a dividere il dataset in classi sulla base delle caratteristiche delle covariate. L'obiettivo è ottenere classi finali il più possibile omogenee al loro interno rispetto alla distribuzione del target. Gli split sono dicotomici; il numero di split effettuati è uno dei criteri che definisce la complessità dell'albero.

cp	ROC	Sens	Spec
0.000000000	0.8916686	0.9511849	0.6307359
0.002314815	0.8908098	0.9553710	0.6261905
0.003472222	0.8973140	0.9602564	0.6216450
0.004629630	0.8993634	0.9623543	0.6216450
0.006944444	0.8818685	0.9658411	0.6123377
0.007716049	0.8700084	0.9700126	0.5790043
0.009259259	0.8615764	0.9734994	0.5651515
0.023148148	0.8043857	0.9797883	0.5134199
0.039351852	0.8052128	0.9749029	0.5179654
0.131172840	0.5855983	0.9846785	0.1640693

ROC was used to select the optimal model using the largest value.
The final value used for the model was cp = 0.00462963.

L'albero migliore che viene proposto presenta un cp (parametro di complessità) prossimo a 0 (0.00462963) che porta al miglior valore della metrica ROC (0.8993634).

Mediante il grafico è possibile visualizzare l'andamento della ROC in funzione del parametro di complessità, influenzato dal numero di nodi finali. Sulla destra si mostra la matrice di confusione.

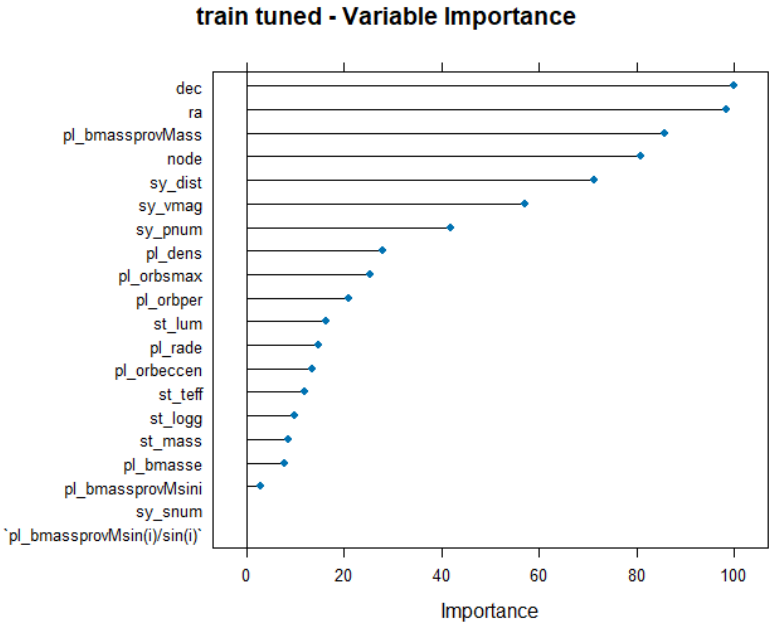


Matrice di confusione

Prediction \ Reference	no	yes
no	83.6	5.0
yes	3.3	8.1

Accuracy (average) : 0.9176

Dopo avere addestrato l'albero si possono visualizzare le covariate più importanti, ricavate sommando tutti i decrementi di impurità che esse generano nei vari nodi dell'albero.



Le variabili più importanti risultano essere:

- *dec;*
- *ra;*
- *pl_bmassprov;*
- *node;*
- *pl_orbper;*
- *pl_orbsmax;*
- *pl_rade;*
- *sy_pnum;*
- *sy_vmag;*
- *pl_bmasse;*

2. Random Forest

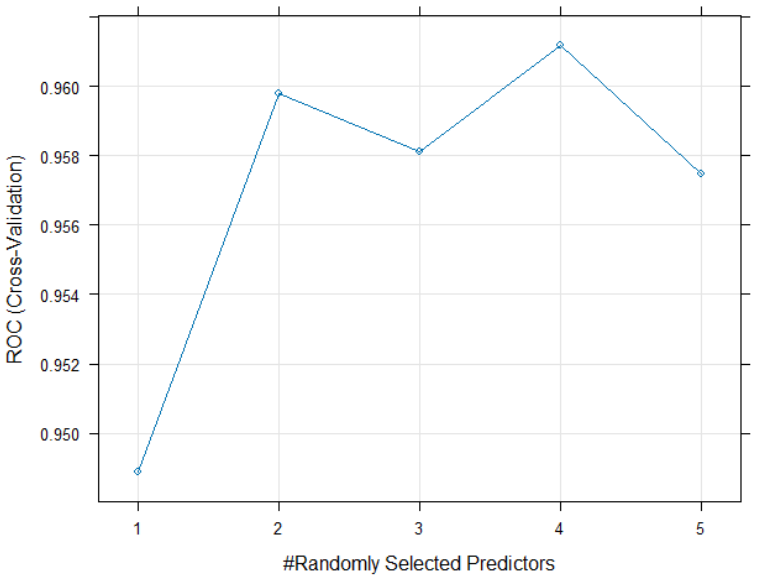
Il random forest è un modello ensamble che combina diversi alberi ottenuti da diversi campioni bootstrap dei dati. Per ogni campione viene selezionato un sottoinsieme di k covariate casuali. Questo approccio permette di ridurre la variabilità degli alberi singoli.

I parametri di tuning in un random forest sono il numero di covariate selezionate casualmente da ciascun albero e il numero di campioni bootstrap.

```
mtry  ROC        Sens       Spec
1     0.9488951  0.9986111  0.3188312
2     0.9597798  0.9909237  0.6623377
3     0.9581126  0.9874320  0.6761905
4     0.9611716  0.9867327  0.6757576
5     0.9574881  0.9874369  0.6807359

ROC was used to select the optimal model using the largest value.
The final value used for the model was mtry = 4.
```

Il modello vincente che massimizza la ROC è quello con 4 covariate. Inoltre, si visualizza la matrice di confusione.



Matrice di confusione

	Reference	
Prediction	no	yes
no	85.8	4.2
yes	1.2	8.8

Accuracy (average) : 0.9461

Dopo avere addestrato il random forest si possono visualizzare le covariate più importanti, ricavate sommando tutti i decrementi di impurità che esse generano nei vari nodi dell'albero in ogni campione bootstrap.

	Overall
pl_bmassprovMass	100.000
sy_pnum	79.006
dec	65.916
pl_dens	64.109
pl_rade	57.046
pl_bmasse	51.986
pl_orbper	50.977
pl_orbsmax	50.822
ra	48.164
sy_vmag	44.725
sy_dist	39.629
st_lum	35.957
node	32.824
st_teff	32.294
st_logg	28.792
st_mass	27.738
pl_orbeccen	24.568

3. Modello Logistico

Il modello logistico è un classificatore lineare che fornisce punteggi discriminanti attraverso la funzione logit. Per ricavare le posterior da questi punteggi si utilizza la funzione logistica senza ricorrere al teorema di Bayes. I preprocessing svolti per questo modello sono stati:

1. la model selection attraverso il random forest;
2. lo studio della collinearità;
3. la missing imputation;
4. near zero variance
5. Separation.

Inoltre si visualizza la matrice di confusione.

Metrica di tuning ROC

ROC	Sens	Spec
0.8877347	0.9734848	0.5454545

Matrice di confusione

Prediction	Reference no	yes
no	84.6	5.9
yes	2.3	7.2

Accuracy (average) : 0.9176

4. Lasso

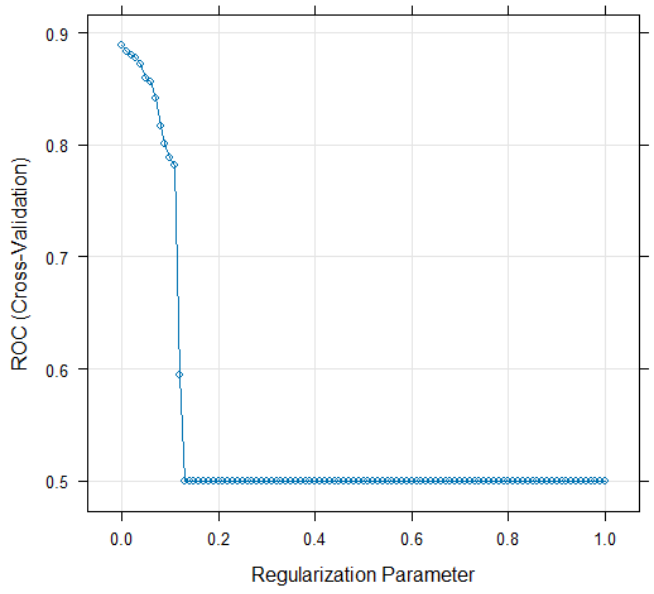
Il modello lasso minimizza la residual sum of square, come OLS, ma pone un vincolo λ alla somma dei valori assoluti dei coefficienti. Questo parametro di penalizzazione permette di ridurre a zero la stima dei coefficienti per ridurne la variabilità.

lambda	ROC	Sens	Spec
0.00	0.8884981	0.9741793	0.540692641
0.01	0.8834338	0.9797640	0.559523810
0.02	0.8802096	0.9881459	0.452597403
0.03	0.8778445	0.9916327	0.235497835
0.04	0.8716320	0.9951146	0.101515152
0.05	0.8593861	0.9972028	0.041774892
0.06	0.8555970	1.0000000	0.009307359

The final values used for the model were alpha = 1 and lambda = 0.

Il modello vincente ha come coefficiente di penalizzazione lambda pari a 0 e alpha pari a 1. Produce lo stesso risultato del modello logistico.

Si visualizzano sia l'andamento del parametro ROC rispetto al parametro di regolarizzazione λ che la matrice di confusione.



Matrice di confusione

Prediction	Reference no	yes
no	84.7	6.0
yes	2.2	7.1

Accuracy (average) : 0.9176

5. Naive Bayes con Tree

Il modello naive bayes è un modello classificativo derivante dal classificatore bayesiano, che trasforma una densità k-variata nel prodotto di k densità univariate assumendo l'indipendenza delle osservazioni. Il naive bayes soffre di collinearità, zero frequency problem, che si ha quando una sola covariata pari a 0 annulla le posterior di quel soggetto. Si addestra il modello sul dataset di training ricavato dall'albero decisionale al punto 1.

```
  usekernel  ROC        Sens       Spec
  FALSE      0.7588682  0.3381362  0.9443723
   TRUE      0.7466512  0.8645639  0.4389610

Tuning parameter 'laplace' was held constant at a value of
 0
Tuning parameter 'adjust' was held constant at a value of 1
ROC was used to select the optimal model using the largest value.
The final values used for the model were laplace = 0, usekernel
 = FALSE and adjust = 1.
```

Si visualizza la matrice di confusione del naive bayes con l'albero.

Matrice di confusione

```
          Reference
Prediction   no  yes
       no  29.4  0.7
       yes 57.5 12.4

 Accuracy (average) : 0.4176
```

Si nota che rispetto ai modelli precedenti si ha un alto tasso di errata classificazione nei falsi positivi.

6. Naive Bayes con Random Forest

Si applica lo stesso modello del punto precedente, utilizzando come dataset di training quello fornito dal modello random forest.

```
  usekernel  ROC        Sens       Spec
  FALSE      0.7735094  0.2803079  0.9586580
   TRUE      0.7902072  0.9937160  0.1162338

Tuning parameter 'laplace' was held constant at a value of
 0
Tuning parameter 'adjust' was held constant at a value of 1
ROC was used to select the optimal model using the largest value.
The final values used for the model were laplace = 0, usekernel
 = TRUE and adjust = 1.
```

Si visualizza la matrice di confusione del naive bayes con random forest.

Matrice di confusione

```
          Reference
Prediction   no  yes
       no  86.4 11.6
       yes  0.5  1.5

 Accuracy (average) : 0.8788
```

Si nota un alto tasso di errata classificazione nei falsi negativi.

7. Partial least squares (PLS) con Random Forest

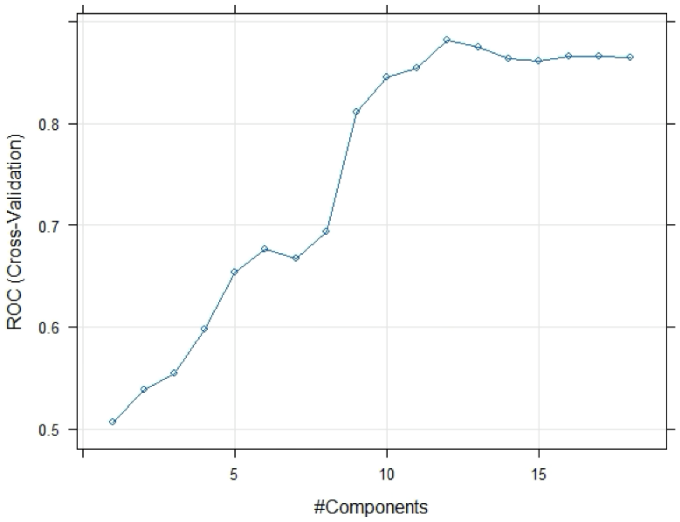
Il modello PLS è molto simile al metodo delle componenti principali (PCA), ma è considerato più completo in quanto trova la migliore combinazione lineare che spiega sia la varianza delle covariate, che del target. L'unico preprocessing effettuato è la model selection, che è stato risolto adottando il dataset di training ottenuto con il modello random forest.

```
  10      0.8455961  0.9951098  0.087662338
  11      0.8549004  0.9818522  0.129653680
  12      0.8815640  0.9909188  0.250432900
  13      0.8751853  0.9874272  0.407792208
  14      0.8639118  0.9769814  0.565800866
  15      0.8616477  0.9776758  0.574675325
  16      0.8653969  0.9783751  0.565584416
  17      0.8653900  0.9790695  0.570129870
  18      0.8650125  0.9776709  0.574675325

ROC was used to select the optimal model using the
 largest value.
The final value used for the model was ncomp = 12.
```

Il parametro di tuning per il modello è il numero di componenti da estrarre, che in questo caso è pari a 12.

Si visualizzano sia l'andamento della metrica ROC rispetto al numero di componenti che la matrice di confusione del modello PLS.



Matrice di confusione

```
            Reference
Prediction   no  yes
       no  86.1  9.8
       yes  0.8  3.3

 Accuracy (average) : 0.8939
```

8. Bagging Tree

Il bagging tree è un modello ensamble che combina diversi alberi ottenuti da diversi campioni bootstrap dei dati. Questo approccio permette di ridurre la variabilità degli alberi singoli.

Il parametro di tuning è il numero di campioni bootstrap.

Metriche di tuning ROC

ROC	Sens	Spec
0.9419301	0.9832653	0.6714286

Si visualizza la matrice di confusione del modello bagging tree.

Matrice di confusione

	Reference	
Prediction	no	yes
no	85.5	4.3
yes	1.5	8.8

Accuracy (average) : 0.9424

9. Gradient Boosting

Il gradient boosting è un modello ensamble che cerca di migliorare le prestazioni classificative, fornendo la somma pesata delle regole classificative degli M classificatori (tipicamente alberi), con un coefficiente che indica il contributo del modello nell'iterazione m-esima. Il gradient boosting utilizza come algoritmo di aggiornamento dei pesi il gradient descent. Di conseguenza i paramentri di tuning sono: numero di iterazioni, complessità dell'albero e learning rate.

interaction.depth	n.trees	ROC	Sens	Spec
1	50	0.9031421	0.9895299	0.4036797
1	100	0.9189771	0.9874417	0.4688312
1	150	0.9283774	0.9860480	0.4913420
1	200	0.9305740	0.9846445	0.5054113
1	250	0.9336007	0.9825612	0.5051948
2	50	0.9275825	0.9846542	0.5196970
2	100	0.9407535	0.9839598	0.5424242
2	150	0.9436160	0.9839646	0.5751082
2	200	0.9458799	0.9839646	0.6021645
2	250	0.9499749	0.9825758	0.6069264
3	50	0.9347474	0.9867473	0.5335498
3	100	0.9475872	0.9839744	0.5844156
3	150	0.9516212	0.9846688	0.6119048
3	200	0.9537206	0.9797786	0.6348485
3	250	0.9535032	0.9811723	0.6575758
4	50	0.9454909	0.9811820	0.5751082
4	100	0.9520667	0.9818813	0.6253247
4	150	0.9551567	0.9818910	0.6391775
4	200	0.9563141	0.9846688	0.6530303
4	250	0.9567667	0.9832799	0.6857143
5	50	0.9457891	0.9846688	0.5844156
5	100	0.9568136	0.9811917	0.6209957
5	150	0.9574191	0.9832848	0.6346320
5	200	0.9569612	0.9811966	0.6857143
5	250	0.9579381	0.9818910	0.6811688

```
Tuning parameter 'shrinkage' was held constant at a value
 of 0.1
Tuning parameter 'n.minobsinnode' was held constant
 at a value of 10
ROC was used to select the optimal model using the
 largest value.
The final values used for the model were n.trees =
 250, interaction.depth = 5, shrinkage = 0.1 and
 n.minobsinnode = 10.
```

Si visualizza la matrice di confusione del gradient boosting.

Matrice di confusione

```
          Reference
Prediction   no  yes
       no  85.3  4.2
       yes  1.6  8.9

 Accuracy (average) : 0.9424
```

10. Adaboost

L'adaboost, così come il gradient boosting, è un modello ensamble che cerca di migliorare le prestazioni classificative, minimizzando il tasso di errore. Durante ogni iterazione si stima un albero sul dataset e vengono calcolate le prediction. In seguito ad ogni soggetto viene assegnato un peso che aumenterà nell'iterazione successiva nel caso in cui non venga classificato correttamente. Nell'iterazione successiva viene costruito un campione estraendo i soggetti aventi un peso maggiore e l'algoritmo andrà a lavorare su tali soggetti.

Il parametro di tuning è il numero di iterazioni.

```
  nIter  method         ROC        Sens       Spec
   50    Adaboost.M1    0.9522751  0.9825758  0.7183983
   50    Real adaboost  0.6158984  0.9944153  0.5645022
  100    Adaboost.M1    0.9554926  0.9811772  0.7181818
  100    Real adaboost  0.6410537  0.9923271  0.6110390
  150    Adaboost.M1    0.9556321  0.9818813  0.7043290
  150    Real adaboost  0.6491473  0.9930216  0.5878788

ROC was used to select the optimal model using the
 largest value.
The final values used for the model were nIter = 150 and
 method = Adaboost.M1.
```

Il parametro di tuning, ovvero il numero di iterazioni che fornisce il valore più alto di ROC è 150, come mostrato dall'output.

Si visualizza la matrice di confusione del modello adaboost.

Matrice di confusione

```
          Reference
Prediction   no  yes
       no  85.3  3.9
       yes  1.6  9.2

 Accuracy (average) : 0.9455
```

11. Reti neurali con Tree

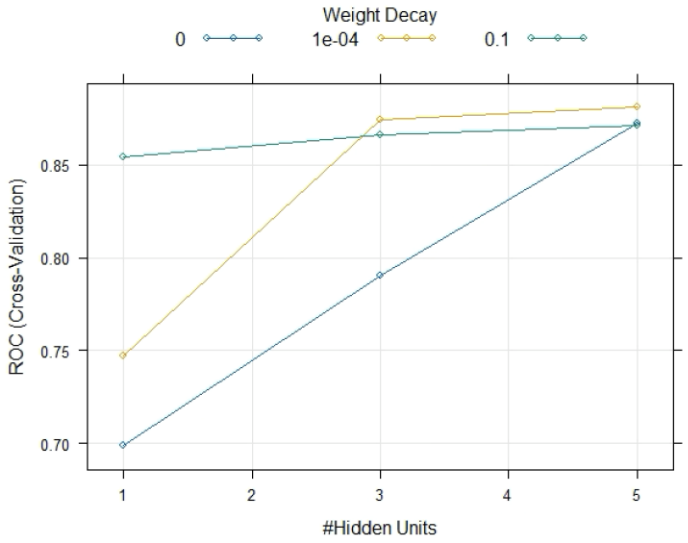
La rete neurale è un metodo di apprendimento automatico che cerca di generare un output il più vicino possibile alla variabile dipendente. Nel software R è implementata una rete Multilayer percepton composta da un singolo strato nascosto contenente diversi neuroni. La rete necessita dei seguenti preprocessing:

- Gestione dei dati mancanti;
- Model selection, risolto utilizzando il dataset di training fornito dall'albero nel punto 1;

- Normalizzazione delle covariate;
- Gestione della collinearità e della near zero variance.

size	decay	ROC	Sens	Spec
1	0e+00	0.6754742	1.0000000	0.0000000
1	1e-04	0.7380934	1.0000000	0.0000000
1	1e-01	0.8501131	0.9741793	0.2030303
3	0e+00	0.8480075	0.9560412	0.3562771
3	1e-04	0.8651771	0.9588530	0.3880952
3	1e-01	0.8618899	0.9804779	0.2586580
5	0e+00	0.8786785	0.9651272	0.3478355
5	1e-04	0.8843177	0.9630196	0.4391775
5	1e-01	0.8636052	0.9797688	0.2863636

ROC was used to select the optimal model using the
 largest value.
The final values used for the model were size = 5 and decay
 = 1e-04.



Il grafico mostra, per ogni numero di strati nascosti della rete e per ogni valore del parametro che controlla la velocità di apprendimento, i valori delle metriche ROC. Per massimizzare questa metrica è stata scelta la rete con 5 neuroni e un parametro di decay pari a 0.00001

Si visualizza la matrice di confusione della rete neurale con l'albero.

Matrice di confusione

Prediction \ Reference	no	yes
no	83.8	8.1
yes	3.1	5.0

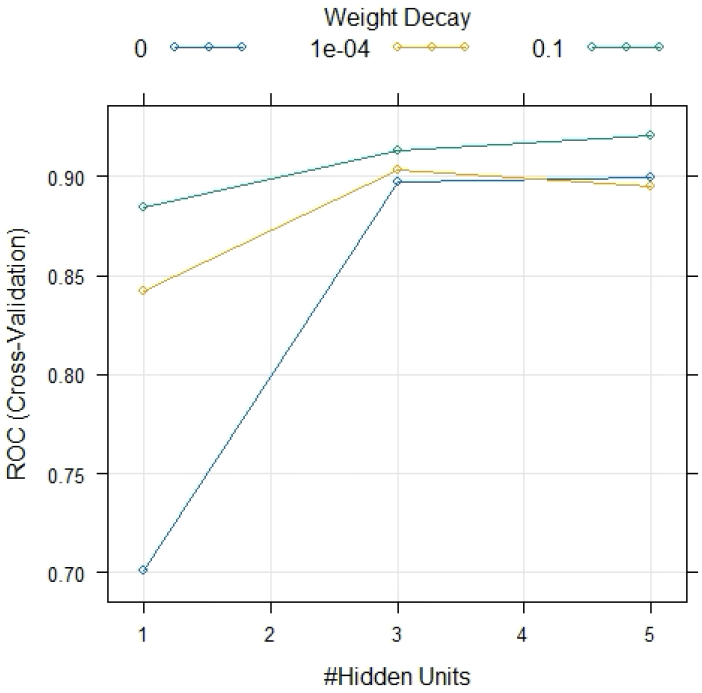
Accuracy (average) : 0.8879

12. Reti neurali con Random Forest

Viene proposto il medesimo classificatore del punto precedente, allenato sul dataset di training fornito dal modello random forest.

size	decay	ROC	Sens	Spec
1	0e+00	0.7007245	0.9818959	0.3212121
1	1e-04	0.8420150	0.9755973	0.5129870
1	1e-01	0.8845489	0.9700078	0.5701299
3	0e+00	0.8968876	0.9762869	0.5608225
3	1e-04	0.9034288	0.9679244	0.5785714
3	1e-01	0.9129362	0.9797640	0.5515152
5	0e+00	0.8996975	0.9672106	0.6158009
5	1e-04	0.8948064	0.9665016	0.5727273
5	1e-01	0.9202670	0.9783654	0.5699134

ROC was used to select the optimal model using the
 largest value.
The final values used for the model were size = 5 and decay
 = 0.1.



Il grafico mostra, per ogni numero di strati nascosti della rete e per ogni valore del parametro che controlla la velocità di apprendimento, i valori delle metriche ROC. Per massimizzare questa metrica è stata scelta la rete con 5 neuroni e un parametro di decay pari a 0.1

Si visualizza la matrice di confusione della rete neurale con random forest.

Matrice di confusione

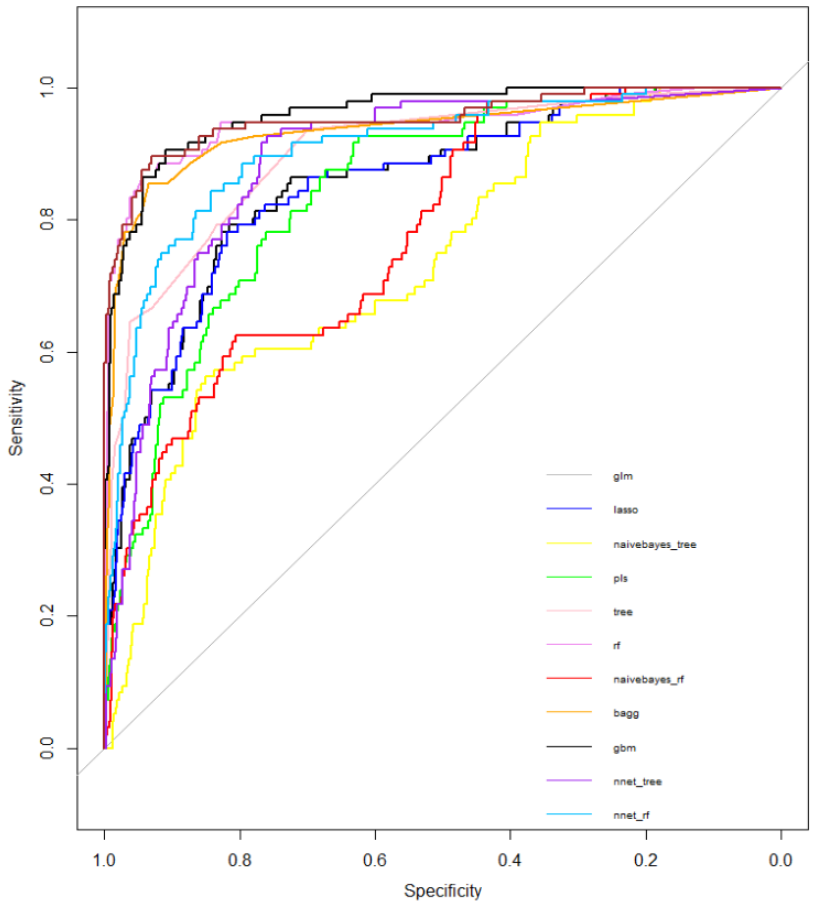
Prediction	Reference no	yes
no	85.0	5.6
yes	1.9	7.5

Accuracy (average) : 0.9248

STEP 2: CONFRONTO MODELLI

In questo step vengono riproposti i modelli fittati nella fase precedente sul dataset di validation al fine di individuare il modello migliore secondo la metrica di riferimento. Nell'analisi si è scelto di utilizzare la curva ROC in quanto non risente della variazione della soglia scelta.

La curva mostra la relazione tra la sensitivity e il complemento a uno della specificity. Questo permette di valutare quanto ogni modello classifica correttamente le osservazioni per tutte le soglie possibili.



Per valutare la bontà di una curva ROC si osserva l'AUC, ovvero l'area compresa tra la curva e la bisettrice.

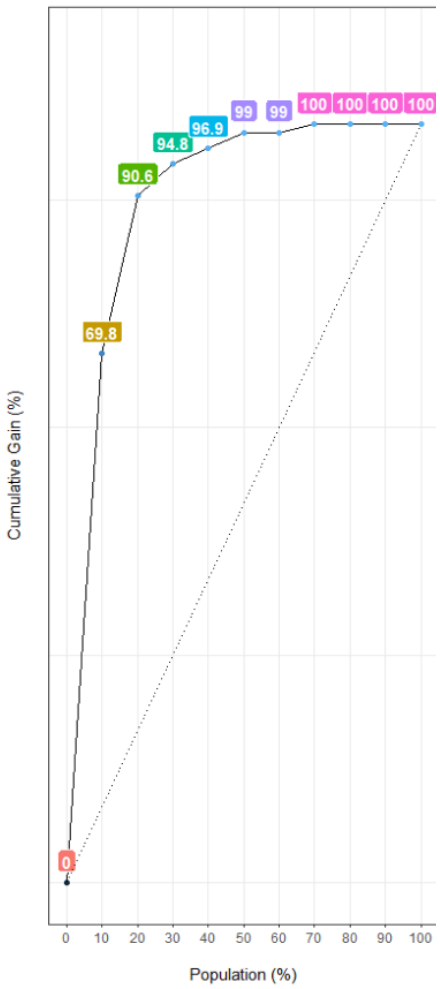
Maggiore è l'area individuata, più il modello è considerato un buon classificatore.

Come si è osservato precedentemente, l'algoritmo Naive Bayes è quello che presenta performance peggiori. Volendo valutare i modelli che offrono una misura dell'AUC migliore, la situazione è più complicata, dal momento che dal grafico è difficoltoso riuscire ad individuare con precisione i modelli che mostrano un'area sotto la curva più ampia.

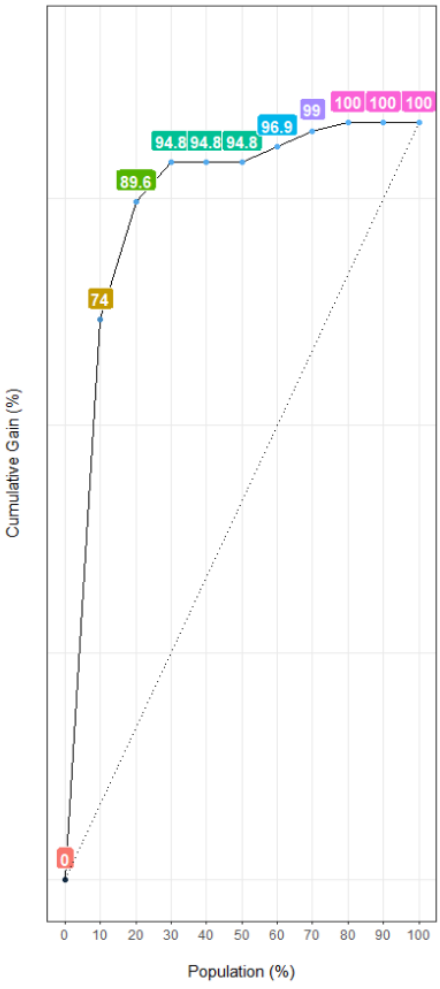
Tuttavia, si può riconoscere dalla figura che i modelli gradient boosting, adaboost e random forest producono performance classificative migliori.

Per identificare quali tra questi sia quello ottimale, bisogna ricorrere ad una valutazione più accurata, anche se meno robusta, per scegliere coerentemente il modello. Si decide quindi di analizzare le curve Lift. Questo metodo suddivide la distribuzione dei valori previsti in decili e il modello viene valutato nei primi decili.

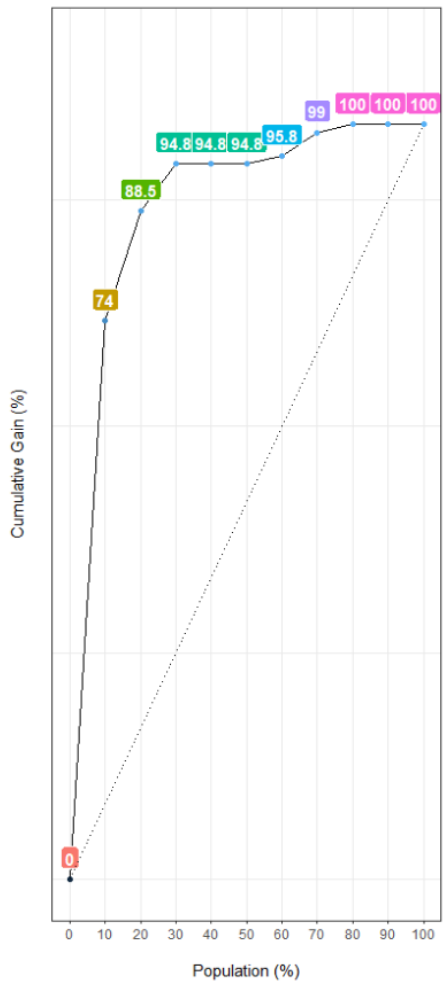
Lift chart gradient boosting



Lift chart adaboost



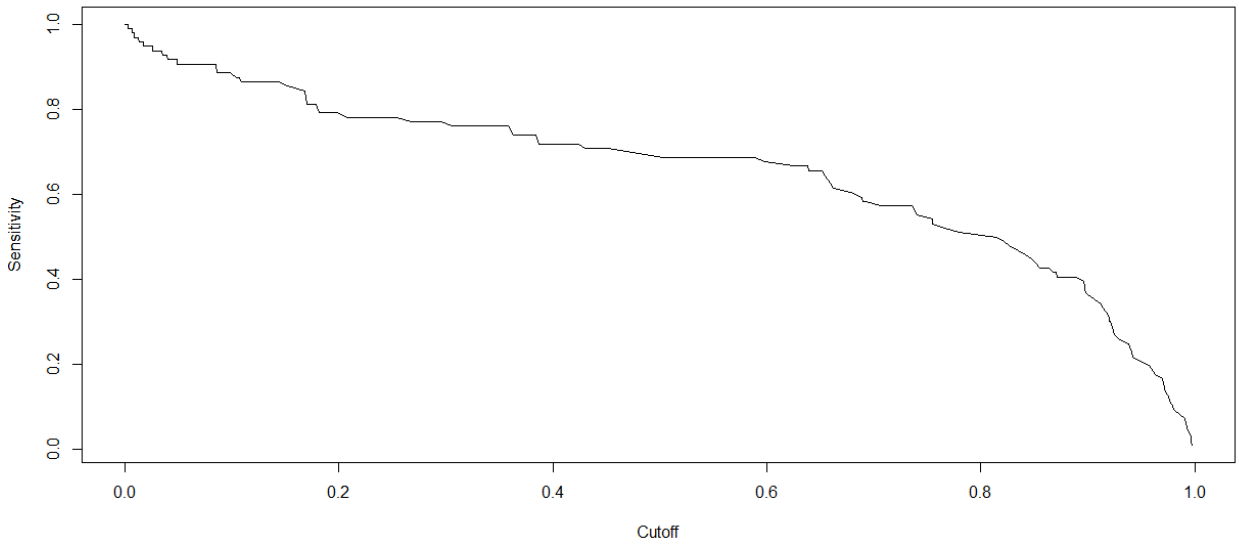
Lift chart random forest



Dalle analisi delle curve ROC si è scelto di valutare le performance classificative dei modelli fino al secondo decile per scegliere quale considerare come vincente. Si sceglie il gradient boosting in quanto riesce a catturare il 90,6% della popolazione nei primi 2 decili contro l'89,6% dell'adaboost e l'88,5% del random forest.

STEP 3: SCELTA DELLA SOGLIA

In questo terzo step si sceglie il valore della soglia da applicare, nello step 4, alle posterior che si ottengono sui dati di score per classificare i nuovi soggetti. Per determinare questo valore con più precisione possibile, ci si è voluti concentrare sulla sensitivity. Questa metrica permette di minimizzare la classificazione dei falsi negativi, ovvero quei pianeti in cui la variazione dei tempi di transito risulta assente quando in realtà è presente. Non rilevare un'eventuale variazione infatti, precluderebbe la possibilità di effettuare ulteriori analisi sul pianeta in questione e sui legami di questo con altri corpi celesti, non osservabili tramite tecniche tradizionali.



Osservando la figura e tenendo conto dello studio fatto in precedenza si è scelta una soglia pari a 0.2

STEP 4: SCORE

Una volta definito il modello vincente e scelta la soglia decisionale che massimizza i soggetti che si è interessati a classificare in modo corretto, è possibile effettuare una previsione dei soggetti su un dataset di score.

Score

N	Y
0.8472727	0.1527273

In conclusione il modello gradient boosting ha permesso di giungere all'obiettivo prefissato all'inizio dell'analisi poiché si è ottenuto il classificatore migliore nel prevedere correttamente gli esopianeti che presentano la variazione dei tempi di transito, conoscendo le loro principali caratteristiche. Questo risultato potrà essere sfruttato da agenzie spaziali per individuare questa proprietà, utile per ipotizzare l'esistenza di nuovi pianeti non osservabili attraverso tecniche tradizionali, pur non avendo a disposizione tutti i dati relativi all'esopianeta di interesse.